

机器与连接（草案） + 诊断附录

机器与连接

这一页讲清楚话题、席位、会话、工作机分别是什么，模型调用和文件命令各在哪台机器上跑，以及连接出问题怎么排查。

四个概念

这四个词在其他页面经常一起出现，先各给一句定义。

话题

话题是一个协作房间：人和 AI 队友在里面发消息、派任务、看进度。每个话题有自己的文件和成果。

席位

席位是房间里的一个位置，坐着一个人或一个 AI 队友。房间顶部的成员头像就是名册上的席位。

会话


会话是 AI 队友席位上正在跑的那段工作：它记得这个队友读到了哪、正在做什么。会话跑在平台共用的会话宿主上，不在你的工作机上。

工作机

工作机是读写文件、跑命令、打开预览的那台机器。一个话题一台，房间里所有 AI 队友共用；可以是云端机器，也可以是接入的自有设备。

模型和文件各跑在哪

AI 队友的「想」和「动手」在两个地方，用一张图分清：



—— 工作机（本话题一台）

读写文件、跑命令、起预览

发消息后的第一条回复来自会话宿主；工具结果（改了什么文件、命令输出）来自工作机。

三种「卡」对应三个地方

「卡」先分是哪一种，再决定找谁。

- 发消息后第一条回复慢：会话宿主或模型服务。
- 回复正常、跑命令和读写文件慢：工作机。
- 预览打不开：工作机上的预览隧道。预览隧道一个话题一条，换机或机器回收后旧地址失效，重新打开预览即可。

默认用哪台

没选过工作机的话题按顺序继承：项目默认（「项目设置 → 工作电脑」）→ 团队默认 → 平台默认。改默认只影响还没开工的 AI 队友，正在跑的不受影响。每个 AI 队友现在用哪台，写在房间名册里。选择和更换的操作步骤见[设备与工作电脑](#)。

换机影响整个话题

换机对整个话题生效，不是只换某一个席位。平台按下面几步搬：

1. 先把房间里每个 AI 队友的改动推送到各自的分支。
2. 全部推上去才换；有一个推不上去就整个不换，并写明原因。
3. 新机器从分支拉代码继续。正在运行任务的队友跳过，稍后再换。

原来那台连不上时，平台会问你要不要「不推送，直接更换」：没推上去的改动不会跟过去。刚换完的一小段时间里，名册可能暂时显示不同的机器，那是搬迁的中间态，稍等刷新。话题归档后，它的云端工作机自动释放。

资源边界

云端工作机是共享宿主机上的容器，核数和内存由建话题时选的机型决定（档位表待补，见文末「还没核实的」）。宿主机上的其他负载可能间接影响你的速度。容器里看到的部分系统读数（负载、磁盘）反映的可能是整台宿主机，不只是这个话题。自有设备的资源边界就是你那台机器本身。

连接出问题时

按现象对照处理：先照抄提示原文，再看意思和处理。

「云端工作电脑正在准备并接入」

意思：云端工作机在开机接入，对话和平台工具仍可用。冷启动可能要两三分钟。处理：等。超过约 15 分钟还没好，在名册里换一台（步骤见[设备与工作电脑](#)）。

设备显示「离线」

意思：自有设备与平台断开。处理：按[常见问题与排障](#)里的设备离线步骤处理。云端工作机状态异常就在名册里换机。

「对话太长，正在整理上下文；整理完会接着处理，期间不会回复」

意思：AI 队友的会话在整理（压缩）长对话，发生在会话宿主，和工作机无关；整理期间不回复是设计如此。对话很长时可能反复出现。处理：看这条消息的变化。变成「上下文已整理，接着处理」就继续；变成「上下文整理没有完成」就截图反馈。状态栏显示「整理上下文中」说明仍在整理。长时间停在「正在整理」且状态栏没有活动，截图反馈。不用换机、不用重启，整理不在工作机上。

预览打不开

意思：预览隧道生在工作机上，换机或机器回收后旧地址失效。处理：重新打开预览；刚换过机就用新地址。

只有某条命令慢

意思：通常是这条命令本身吃资源。装依赖、跑全量测试会把内存盘占满，可能把机器打到离线。处理：先看任务在跑什么；大命令跑完前别叠加新的大命令。

这一版还没核实的

以下几条在这版草案里还没有权威来源，先标出来。

- 各机型的核数、内存档位表：待产品确认后补。
- 「超过约 15 分钟换机」的 15 分钟是经验值，不是平台承诺。
- 会话宿主和模型服务的速度、排队指标目前没有用户可读的看板；觉得整个平台都慢时，截图话题状态找管理员。
- 本文界面字样核对于 2026-09-30 的 dev 环境，以当期产品为准。

诊断附录：原始读数与未决项

本附录附在《机器与连接》草案之后，给核对数据用。所有读数注明窗口、来源、单位、范围；测不到的标 unknown，不补猜。

代码基准

- 部署 SHA: 9d035d8353b36d3ccd09e202cdd7d4a4bd523af7 (= main, PR #2216, 前端改动)。以 /api/health 的 data.version 为准。
- 本地比对: /tmp/cheese-src 浅克隆 b0aa4cd..origin/main 对本文引用的 14 个文件 git diff 为零，代码结论在部署 SHA 上成立。
- 2026-09-30 上午三次部署：进程起于 08:03:37Z、约 08:25–08:50、08:58:24Z (uptime 反推 + version 变化确认)。进程内指标随部署清零。

采样机与窗口

- 机器：本话题云端工作机 (LXC 容器, pve119 宿主)，8 核 cpuset (25,31,34,49,70,77,103,120)，窗口约 2026-09-30 07:30–09:30Z 内的多次短采样。
- 采样方法：cgroup v2 命名空间根即容器根；cpu.stat 差分得单核占比；memory 读 anon 不读 current (file page cache 可回收)。

四层读数（示例，不代表平台）

层	读数	窗口	单位
cheese.service 子树 CPU	约 2.3% 单核	5 分钟差分	单核占比
容器可见总量 CPU	轻载	同上	单核占比
宿主 /proc/loadavg	≈35	瞬读	宿主整机背景，与本容器无关
宿主侧 LXC 限额	unknown	—	容器内不可见

容器可见层级 cpu.max/memory.max/pids.max 全为 max，不证明宿主没限；io 控制器未委派，容器级磁盘 MB/s 测不到 (unknown)。

admin 读数 (wangchangxin 以管理员身份取)

指标	读数	时刻	语义边界
performance uptime	149.47s / 576.075s	约 08:06Z / 约 09:06Z	单进程，随部署清零
有样本路由	31 / 48（注册 685）	同上	中间件计数
active_requests	7 / 5	同上	call_next 返回后减，流式不在账
loop_lag recent / worst	69ms / 751ms; 170ms / 1213ms	同上	recent=最近一次 0.25s 探针；worst=进程启动以来含启动期
network api rx/tx	319 / 4629 字节每秒	约 09:06Z	仅 HTTP 载荷（Content-Length 计），无 WS/health/流式
uplink	null	同上	设计即 None，不可读不出 0
delivery unsent / dead	139 / 0	两次相同	全库计数，无 receiver 过滤
oldest_unsent_at	2026-09-24T02:20:13Z	—	无 attempts 过滤
项目 usage 累计	input 28,387,485,990; output 252,925,865; turns 24,209	约 09:08Z	累计量，非速率

两次 usage 快照差分（约一小时区间，起止时刻不精确）： $\Delta \text{turns}=7$ 。只说明「窗口内落账的归属单元约 7 个」，推不出并发高低：turns 是 distinct turn_id 归属计数（repositories.py:87-112），订阅链路 30s 近实时落账、网关链路轮末才落，在跑长轮在差分里看不到。

delivery_unsent 139 的代码级解释

三个查询三种过滤（gaps.py:186-218、integrations.py:139-157）：计数不带 receiver 过滤；重发任务要求 receiver_id IS NOT NULL（ledger.resend_unsent，60s 一轮、每轮 200、最老优先、上限 5 次）；最老时间不带 attempts 过滤。receiver_id 为 NULL 的行永不重试、永不成死信——与「139 未发、0 死信、最老 09-24」完全自治。NULL 行有多少、该不该发：需要只读库权限，unknown。

任务快照备份 500（task 4db75afb，连续三次）

路径：post-commit → cheese sync → git bundle（只含不在 origin/main 的对象）→ PUT /projects/{id}/git/tasks/{id}/snapshots/{sha}（客户端超时 120s）→ 512MiB 上限、digest/magic 校验失败是 422 → R2 上传带服务端 asyncio.timeout(120)，超时/上传错误未捕获 → 500。

结论：500 落在 R2 上传/120s 超时层，push（forge）与备份（R2）是两条独立路径，所以 push 成功、备份 500 不矛盾。大包（二进制多的分支）确定性失败最可能；部署窗口是备选解释。精确定位需要 dev 机后端日志异常类型 + worktree cheese-sync.log 时间戳（都要 sudo），unknown。

长上下文整理样本（话题 422，2026-09-30）

转录里三条「对话太长，正在整理上下文；整理完会接着处理，期间不会回复」：09:43:38.530Z、09:54:12.966Z、09:55:36.777Z。status 无 live_turn；root 保留远端 506ca48a，未重启。

语义（events.py:118-130、prompt.py:343-366、hook_stream.py:385-505）：每条 = 一次 compaction 开始；一轮内原位复写同一块；结束变成「上下文已整理，接着处理」或「上下文整理没有完成」+原因；轮在整理中结束 → 「会话在整理完成前结束了」。发生在会话宿主，与工作机无关。三条消息是三次开始，间隔相加不是模型生成耗时。有没有真实 compaction 结束/重试原因：只读 runtime 入口权限不够，unknown。

first_output_s 语义矩阵

needs_place（=非私聊，chat.py:3870）× provisions_machine：

席位类型	含云端准备？
central_provider（False）	不含
cloud_provider（True）+ 非私聊	含 prepare_topic 最多约 50s 等待；超时则 waiting+done 帧、first_output_s 保持 None

云机超时路径：chat.py:4149-4208 bail，frames=[waiting cloud_provisioning, done]。所以 first_output_s 一律不能当模型 TTFT 用。

未决项（按需要谁排）

1. dev 机 sudo：metering-proxy gateway_request_timing、LiteLLM spend 日志 → provider tokens/s、TTFT 唯一权威来源。
2. dev 机 sudo：4db75afb 备份 500 的异常类型 + cheese-sync.log 时间戳。
3. dev 机只读库：deliveries 表 receiver_id 分桶计数。
4. 产品：机型档位表（核数/内存）确认后补进正文。
5. wangchangxin：稳态 performance 复读（部署后指标已清零两轮）。