AI 为什么慢，怎么改

结论：可以补方案，不能把它写成已证实的根治

减少无必要的串行往返值得试，但现有数据不足以认定它是唯一或最大的瓶颈。保留“先回应人”的拦截；不改工具链。取消进度提醒、提前压缩、换缓存结构，都不直接实施。先修正计时口径，再用同一任务的对照结果决定改哪里。

原 PDF 中需要改掉的六处

原说法	核验与订正
每次调用中位 7 秒	表中是“整轮总时长 ÷ 原表调用数”。八个比值的中位数为 7.05 秒，并非全部单次模型请求的中位耗时；不能拿它乘减少的调用数，承诺提速。
20 次里 9 次低于 2 秒，中位 1.73 秒	两句不能同时成立：排序后第 10、11 个数都至少 2 秒。聊天中的“9 次”原属 14 个样本；20 个样本的完整明细尚未复算，撤下这组精确统计。[1]
首字快，所以人不必久等	模型首帧可能是思考、工具参数或控制事件；它不等于聊天里首次可见回复。必须分别计量，不能互相代替。
上下文无关，缓存没空间	低相关性不能证明压缩无效；读到 38–46 万缓存 token 也不是完整命中率。缺同请求的总输入、未缓存输入及慢请求样本，不能排除上下文和缓存因素。
长尾只占 3.3%，先不追	旧分析同时称长尾占模型等待 25%。次数少不代表时间占比小。两项比例本轮未重算，应保留为查证线索，不据此删去排查方向。[2]
提醒别插中间；每条多一次往返	插入既有运行不等于必然新建一次模型请求。实际增量要对齐请求边界；看板状态也不能完全代替对人的进展解释。不整体移除提醒。

能加的四项，按验证顺序推进

1. 先把“几次调用”数清楚

一轮用户任务、模型请求、工具调用、并行批次分别计数。成功和失败都纳入；按请求标识关联计时与用量。没有采到的字段记为缺失，不当成 0。历史记录里的引用内容不能再次计数。

2. 在独立读操作上验证批量与并行

先选互不依赖的读文件、查资料；依赖上一步结果或修改同一资源的操作保持顺序。并行能省模型轮次，也可能只缩短工具等待；两项分开量。不要只再加一句“必须并行”就宣布完成。

3. 新增“异常等待”和“工具慢请求”两条分析

把请求失败后的重试、退避、排队、环境准备单列。工具端再分命令执行和往返残差。先找这些时间是否落在任务结束前必须等待的路径上，再修具体原因；不直接缩短超时或取消重试。

4. 给分析工具提供精简取数能力

现有记录查询会返回完整内容，包括其中引用的旧记录。建议增加只取请求标识、时刻、用量、错误分类的查询或汇总，保留展开原文入口。这是减少无效读取的候选方案，收益待测，不是已证实根因。

证据、边界与验证办法

旧表重算：算术成立，因果归因不成立

整轮耗时（秒）	原表调用数	整轮耗时 ÷ 调用数（秒）
22.6	6	3.77
22.2	7	3.17
72.6	10	7.26
136.1	20	6.81
277.2	29	9.56
618.5	79	7.83
814	119	6.84
1011.3	58	17.44

合计 2,974.5 秒、328 次，合计相除约 9.07 秒。八个比值的中位数约 7.05 秒。这些是对旧表的算术复算，不是对全部原始请求的重新采样。58 次那轮用了 1,011.3 秒，119 次那轮用了 814 秒；任务不同，无法只凭次数判断原因。

旧表“请求前准备”有 6/8 轮不超过 0.4 秒，另两轮为 1.79、1.87 秒。它不能覆盖工具首次准备环境、重试和收尾，也不能据此解释先前未归因的全部时间。[3]

本轮新增的运行证据

查询时刻：2026-11-06 02:54 左右；窗口为此前 7 天。以下是平台可见范围的事件次数，不是本任务失败轮数，不用于计算失败率。

事件	次数	可以说明什么
AI 服务请求失败后重试	711	涉及 2 个项目；需检查重试等待，不能全归入正常模型生成。
上下文整理没有完成	34	涉及 1 个项目；“整理失败”这类异常确实存在，不能一概按正常长上下文分析。
消息插入失败后转排队	28	涉及 2 个项目；提醒或消息不保证每次都成功插入当前运行。

详情还列出本任务的一次请求重试（11 月 2 日 01:00:51）与一次上游断流（11 月 1 日 22:31:49）。时间对得上只证明事件发生过，尚不能把某次 66–105 秒长尾归因给它。[4]

验证怎样才算过

- 固定任务、模型、输出要求和工具数据；区分冷启动与已就绪环境。串行与并行交错执行，并交换先后顺序，重复多组，不拿不同任务或单次最快结果比较。
- 同时记录用户收到首个有效回复的耗时、任务总耗时、模型请求数、工具并发区间、失败与重试、用量及产出正确性。先列样本数与缺失率，再报中位数及慢端分布；小样本不宣称稳定的 p95。
- 优化成立须同时满足：相同产出质量、权限与先回应规则保留、端到端耗时下降；不能只证明工具并行了。本次没有完成该对照实验，因此不承诺提速百分比。
- 网关首字节与模型首帧不在同一边界，差值混有转发、缓冲等时间，不能直接叫“预填充”。工具总时长减命令时长也先叫“残差”，核对范围后再归因。

依据与尚未验证的部分

[1] 文件区《怎么改.pdf》最新一页版（取回版本 b013d08798660f89）；本任务聊天 11 月 2 日 01:02 的 14 样本汇总、01:38 的 20 样本汇总。
[2] 本任务 11 月 1 日 22:02 的旧分析：1,528 次调用、长尾占等待 25%、工具占 33%。本轮只核对报告逻辑，未重建该全量样本和回归。
[3] 旧表与逐项数据来自本任务 11 月 2 日 00:35 的汇总。数值由计算复核；“下午”的旧时间描述撤下，避免与跨日时区混淆。
[4] 平台运行记录 7 天窗口：api_retry、context_compact、delivery_fallback；详情确认本任务事件。事件可重复或相关，不能相加当独立故障。时间均按负责人当地时间列示。
当前主干参照 de0ecaac4（PR 5182），仅代表代码核对基线，不代表本轮核实了部署。逐请求缓存关联、用户可见首回复耗时、并行对照及长尾因果仍未验证。本次仅修订报告，不改产品行为。